

Đại học Quốc gia TP. HCM
Trường Đại học Khoa học Tự nhiên
Bộ Môn Khoa học Máy tính



BÁO CÁO CUỐI KÌ FACE RECOGNITION

Nhận Dạng (CSC14006)

Nhóm 9

TP Hồ Chí Minh, ngày 30/07/2021

Contents

1	Thông tin nhóm	3
2	Phân công các thành viên trong nhóm	3
3	Lý thuyết	4
3.1	Kiến thức về Local Binary Patterns (LBP)	4
3.1.1	$LBP_{P,R}$ (1996)	5
3.1.2	$LBP_{P,R}^{ri}$ (2000)	7
3.1.3	$LBP_{P,R}^{riu2}$ (2002)	7
3.1.4	Adjacent Evaluation LBP (AELBP)	9
3.2	Kiến thức PCA (Principal Component Analysis) và (LDA) Linear Discriminant Analysis	11
3.2.1	PCA	11
3.2.2	LDA	13
3.2.3	Sự khác biệt giữa PCA và LDA	15
3.3	Kiến thức về Support Vector Machines (SVM)	15
3.3.1	Ví dụ minh họa SVM	15
3.3.2	Một số hàm kernel thông dụng	16
3.3.3	Phân biệt chiến lược one vs all và one vs one	16
3.4	Kiến thức về mạng nơron cơ bản (ANN)	17
3.4.1	Cấu trúc mạng đề nghị	17
3.4.2	Tính hiệu quả của cấu trúc đề nghị	17
3.5	Kiến thức về mạng nơron sâu (DNN)	18
3.5.1	mạng nơron sâu thường cho kết quả tốt hơn mạng nơron rộng với cùng số lượng nơron.	18
3.5.2	Hàm kích hoạt (Activation functions)	18
3.5.3	Bộ tối ưu (Optimizer)	19
3.5.4	Drop-out	20

4	Bài tập	21
4.1	Locally Linear Embedding (LLE)	21
4.1.1	Tổng quan	21
4.1.2	Các bài toán liên quan	21
4.1.3	Mô tả thuật toán LLE	23
4.1.4	Đánh giá giải thuật	23
4.2	ArcFace	24
4.2.1	Bài toán	24
4.2.2	Tính năng chủ đạo	24
4.3	Đa dạng trong giải thuật học máy	26
4.3.1	Bài toán	26
4.3.2	Giải pháp sử dụng CNN	26
4.3.3	Giải pháp sử dụng RNN	27
5	Tài liệu tham khảo	28

1 Thông tin nhóm

STT	MSSV	Họ tên	Email
1	18120078	Ngô Phù Hữu Đại Sơn	18120078@student.hcmus.edu.vn
2	18120533	Dương Đoàn Bảo Sơn	18120533@student.hcmus.edu.vn
3	18120164	Lê Minh Đức	18120164@student.hcmus.edu.vn

Table 1: Bảng danh sách thành viên nhóm

2 Phân công các thành viên trong nhóm

STT	Họ tên	Công việc tham gia	Hoàn thành (%)
1	Ngô Phù Hữu Đại Sơn	A-1, B-1, B-2, B-3	100/100
2	Dương Đoàn Bảo Sơn	A-4, A-5	100/100
5	Lê Minh Đức	A-2, A-3	100/100

Table 2: Bảng phân tích tỷ lệ hoàn thành công việc

3 Lý thuyết

3.1 Kiến thức về Local Binary Patterns (LBP)

Đặc trưng ảnh cục bộ (Local Image Texture)

Dấu của hiệu giá trị các pixel xung quanh so với điểm ảnh ở tâm sẽ bất biến với phép chiếu sáng.

$$T \sim t(s(g_0 - g_c), s(g_1 - g_c), \dots, s(g_{P-1} - g_c)) \quad (1)$$

Có 2 kiểu đặc trưng cục bộ:

- *Vuông (Square Neighborhood)*: Các điểm trên vùng đặc trưng cục bộ xếp thành hình vuông (đi theo chiều vòng tròn lượng giác), điểm g_0 cách điểm g_c một khoảng R (bán kính) pixel.
- *Tròn (Circular Neighborhood)*: Các điểm trên vùng đặc trưng cục bộ xếp thành hình tròn (đi theo chiều vòng tròn lượng giác), điểm g_0 cách điểm g_c một khoảng R (bán kính) pixel. Do xếp theo hình tròn nên sẽ có một số điểm phải sử dụng phép nội suy để tính. Trong các nội dung bên dưới, xin sử dụng đặc trưng tròn để bàn.




Figure 1: Đặc trưng vuông bên trái, đặc trưng tròn bên phải

3.1.1 LBP_{P,R} (1996)

$LBP_{P,R}$ xác định giá trị tại điểm ảnh g_c bằng đặc trưng ảnh cục bộ của các điểm xung quanh điểm ảnh đó qua công thức:

$$LBP_{P,R} = \sum_{p=0}^{P-1} s(g_p - g_c) \times 2^p \quad (2)$$

Trong đó:

- $P(Point)$ là số lượng điểm trong vùng đặc trưng cục bộ, mỗi điểm cách nhau một khoảng $\frac{2\pi}{P}$ rad.
- $R(Radius)$ là bán kính của vùng đặc trưng cục bộ.
- g_c là điểm cần tính giá trị $LBP_{P,R}$ (Tâm của hình vuông hay hình tròn).
- g_p là điểm thứ p trên vùng đặc trưng cục bộ.
- s (*sign function*) là hàm dấu:

$$s(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases} \quad (3)$$

Ví dụ: Giá trị của $LBP_{8,1}$ của điểm ảnh ở giữa (hình 2) được tính như sau:

$$LBP_{8,1} = \sum_{p=0}^7 s(g_p - 76) \times 2^p = 1 + 2 + 2^3 + 2^5 + 2^6 = 107$$




Figure 2: Ví dụ $LBP_{P,R}$

Ưu điểm

- Bất biến với phép chiếu sáng. Giúp giảm FRR (False Reject Rate) cho các ảnh được chụp ở các điều kiện sáng tối khác nhau.

Ví dụ: Độ sáng tăng lên nhưng $LBP_{8,1}$ không thay đổi (Hình 3).

$$LBP_{8,1} = \sum_{p=0}^7 s(g_p - 76) \times 2^p = 1 + 2 + 2^3 + 2^5 + 2^6 = 107$$




Figure 3: $LBP_{P,R}$ bất biến phép chiếu sáng

- Không cần phải so sánh 2 vector đặc trưng (Công thức 1).
- Tính toán đơn giản.

Nhược điểm

- Không bất biến với phép xoay.

Ví dụ: khi xoay hình 90 độ theo ngược chiều kim đồng hồ, ta sẽ có giá trị $LBP_{8,1}$ thay đổi (Hình 3).

$$LBP_{8,1} = \sum_{p=0}^7 s(g_p - 76) \times 2^p = 1 + 2^2 + 2^3 + 2^5 + 2^7 = 173$$




Figure 4: $LBP_{P,R}$ không bất biến với phép xoay

3.1.2 $LBP_{P,R}^{ri}$ (2000)

Khắc phục được nhược điểm của $LBP_{P,R}$, $LBP_{P,R}^{ri}$ bất biến với cả phép quay và phép chiếu sáng bằng cách sử dụng giá trị nhỏ nhất để đại diện cho tất cả các ảnh xoay (ảnh được xoay theo chiều đường tròn lượng giác với một góc không đổi).

$$LBP_{8,1}^{ri} = \min_{i=0 \rightarrow P-1} ROR(LBP_{8,1}, i) \quad (4)$$

Trong đó:

- $ROR(x, i)$ là phép xoay bit sang phải của x theo vòng tròn i lần. Tương ứng với việc xoay tập hợp các hàng xóm theo chiều kim đồng hồ.

Ví dụ: Giá trị của $LBP_{8,1}^{ri}$ của điểm ảnh ở giữa (hình 2) được tính như sau:

$$\begin{aligned} 01101011_2 &= 107 \\ 10110101_2 &= 181 \\ 11011010_2 &= 218 \\ 01101101_2 &= 109 \\ 10110110_2 &= 182 \\ 01011011_2 &= 91 \text{ (Nhỏ nhất)} \\ 10101101_2 &= 173 \\ 11010110_2 &= 214 \end{aligned}$$

$$\Rightarrow LBP_{8,1}^{ri} = \min_{i=0 \rightarrow P-1} ROR(LBP_{8,1}, i) = 91$$

3.1.3 $LBP_{P,R}^{riu2}$ (2002)

Đặc trưng của $LBP_{P,R}^{riu2}$ khắc phục được nhược điểm của $LBP_{P,R}^{ri}$ đó là:

- Tính toán nhanh và đơn giản. Với mỗi điểm ảnh, chỉ cần tính một giá trị.
- Sử dụng các *Uniform Patterns* để giảm các trường hợp phép xoay không mang lại nhiều ý nghĩa, do mỗi lần xoay cho các giá trị khác nhau làm không thể hiện được đặc thù của điểm ảnh.

Uniform Patterns: Một mẫu nhị phân được gọi là đồng dạng khi xét chuỗi bit xoay vòng thì có nhiều nhất là 2 lần thay đổi (transitions) từ giá trị bit 0 sang 1 hoặc từ giá trị bit 1 sang 0.

Ví dụ: Với hàng đầu tiên là 9 mẫu *Uniform*. Còn lại là các mẫu *Non-Uniform*. Các mẫu Non-Uniform không mang lại nhiều ý nghĩa trong nhận dạng.




Figure 5: 36 mẫu nhị phân khác nhau của $LPB_{8,R}^{ri}$

$$LBP_{P,R}^{riu2} = \begin{cases} \sum_{p=0}^{P-1} s(g_p - g_c) & U(LBP_{P,R} \geq 2) \\ P + 1 & U(LBP_{P,R}) > 2 \end{cases} \quad (5)$$

Trong đó:

$$U(LBP_{P,R}) = |s(g_{P-1} - g_c) - s(g_0 - g_c)| + \sum_{p=1}^{P-1} |s(g_p - g_c) - s(g_{p-1} - g_c)|$$

Chú thích:

- Hàm U thể hiện số lần chuyển từ bit 0 sang bit 1 và ngược lại của các điểm trên đường tròn.
- $LBP_{P,R}^{riu2}$ là số lượng bit 1 trên đường tròn nếu mẫu đang xét Uniform. Ngược lại, bằng $P + 1$ nếu mẫu không Uniform.

Ví dụ:

- Uniform Pattern

$$LBP_{P,R}^{riu2} = 5$$




Figure 6: Uniform Pattern

- Non-Uniform Pattern

$$LBP_{P,R}^{riu2} = 9$$




Figure 7: Non-Uniform Pattern

3.1.4 Adjacent Evaluation LBP (AELBP)

$$AELBP_{P,R} = \sum_{p=0}^{P-1} s(a_p - g_c) \times 2^p \quad (6)$$

Trong đó:

- a_p được tính bằng cách xem g_p là tâm của một block(adjacent evaluation window) có kích thước $W \times W$ (W cho trước). Sau đó, a_p là giá trị trung bình của các điểm ảnh trong block đó (Không bao gồm g_p). Lưu ý $W=1$ thì AELBP có giá trị bằng với LBP.

Ví dụ: Trong ví dụ dưới, ta chọn điểm g_0 tại góc trái trên, chiều quay ngược chiều lượng giác và $W = 3$. Song việc tính toán sẽ tương tự khi g_0 về góc lượng giác và chiều lượng giác như các phần trình bày trước.

$$AELBP_{P,R} = \sum_{p=0}^{P-1} s(a_p - 118) \times 2^p = 255$$

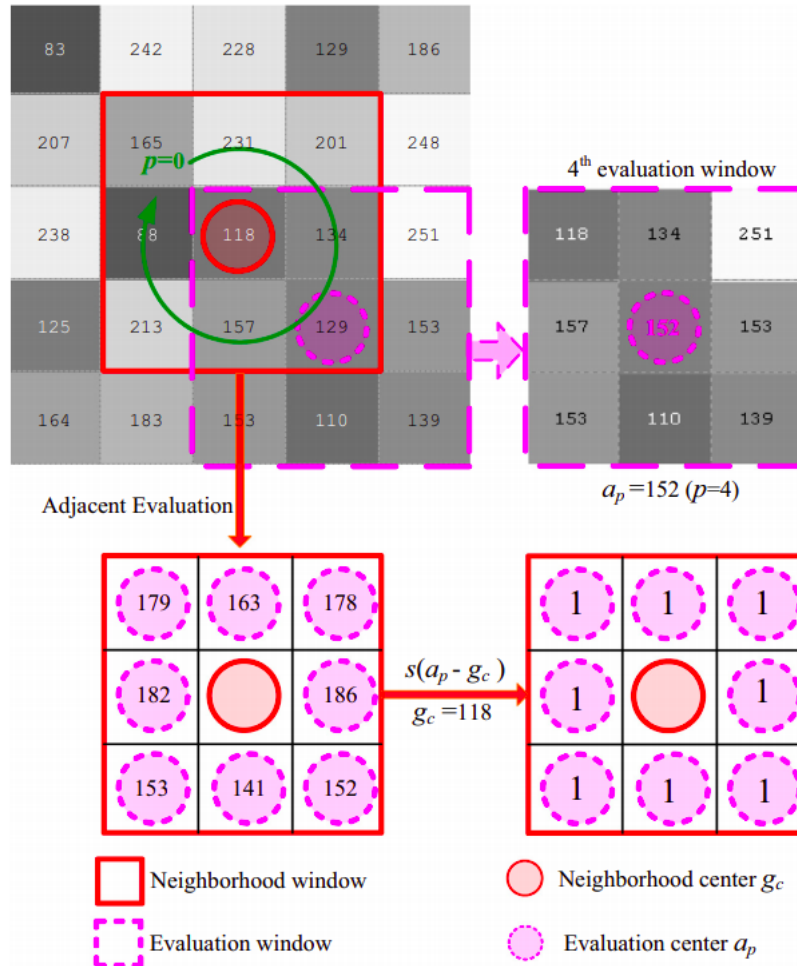


Figure 8: Ví dụ AELBP

Ưu điểm

- AELBP có thể nhận dạng tốt các ảnh có nhiều noise, bằng cách sử dụng giá trị trung bình của lân cận với các điểm g_p . Trong khi LBP thông thường lại rất nhạy cảm với noise.

Nhược điểm

- Tính toán phức tạp hơn so với LBP thông thường.

3.2 Kiến thức PCA (Principal Component Analysis) và (LDA) Linear Discriminant Analysis

3.2.1 PCA

Giả sử ta có: $\langle x_1, x_2, \dots, x_M \rangle_{N \times 1}$. Quá trình thực hiện giảm chiều tập dữ liệu trên bằng PCA được thực hiện qua các bước sau:

- **Bước 1:** Tính các giá trị trung bình của các biến

$$\bar{x} = \frac{1}{M} \sum_{i=1}^M x_i \quad (7)$$

- **Bước 2:** Dời gốc tọa độ về điểm trung bình trong không gian dữ liệu.

$$\Phi_i = x_i - \bar{x} \quad (8)$$

- **Bước 3:** Tính ma trận hiệp phương sai:

$$C = \frac{1}{M} \sum_{m=1}^M \Phi_m \Phi_m^T \quad (9)$$

- **Bước 4:** Tính các trị riêng của C

$$\lambda_1 > \lambda_2 > \dots > \lambda_N \quad (10)$$

- **Bước 5:** Tính các vector riêng tương ứng

$$u_1, u_2, \dots, u_N \quad (11)$$

- **Bước 6:** Giữ lại K vector riêng có trị riêng tương ứng lớn nhất. Do ma trận hiệp phương sai đối xứng, nên các vector riêng đôi một song song nhau và tạo thành một hệ cơ sở. Ma trận chuyển không gian U được hình thành như sau:

$$U = [u_1, u_2, \dots, u_K] \quad (12)$$

- **Bước 7:** Các điểm dữ liệu được chuyển qua không gian mới (có số chiều K « N) theo công thức:

$$b = U^T (x - \bar{x}) \quad (13)$$

Ví dụ minh họa: Có các điểm sau (2.5, 2.4), (0.5, 0.7), (2.2, 2.9), (1.9, 2.2), (3.1, 3.0), (2.3, 2.7), (2, 1.6), (1, 1.1), (1.5, 1.6), (1.1, 0.9). Sử dụng PCA để giảm chúng về 1 chiều.

- **Bước 1:** Tính trung bình, chuẩn hóa.

	x	y		x	y
	2.5	2.4		.69	.49
	0.5	0.7		-1.31	-1.21
	2.2	2.9		.39	.99
	1.9	2.2		.09	.29
Data =	3.1	3.0	DataAdjust =	1.29	1.09
	2.3	2.7		.49	.79
	2	1.6		.19	-.31
	1	1.1		-.81	-.81
	1.5	1.6		-.31	-.31
	1.1	0.9		-.71	-1.01

Figure 9: Tính trung bình, chuẩn hóa

- **Bước 2:** Ma trận hiệp phương sai.

$$cov(X, Y) = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{(n - 1)}$$

$$cov = \begin{pmatrix} .616555556 & .615444444 \\ .615444444 & .716555556 \end{pmatrix}$$

Figure 10: Ma trận hiệp phương sai

- **Bước 3:** Tính vector riêng và giá trị riêng cho ma trận hiệp phương sai.

$$eigenvalues = \begin{pmatrix} .0490833989 \\ 1.28402771 \end{pmatrix}$$

$$eigenvectors = \begin{pmatrix} -.735178656 & -.677873399 \\ .677873399 & -.735178656 \end{pmatrix}$$

Figure 11: Ma trận hiệp phương sai

- **Bước 4:** Biến đổi dữ liệu:

```

[[-0.82797019]
 [ 1.77758033]
 [-0.99219749]
 [-0.27421042]
 [-1.67580142]
 [-0.9129491 ]
 [ 0.09910944]
 [ 1.14457216]
 [ 0.43804614]
 [ 1.22382056]]
    
```

Figure 12: Dữ liệu sao khi biến đổi

3.2.2 LDA

- **Bước 1:** Tính ma trận phân tán giữa các nhóm.

$$S_B = \sum_{i=1}^C c_i (\mu_i - \mu)(\mu_i - \mu)^T \quad (14)$$

μ_i là giá trị trung bình của từng lớp.

μ là giá trị trung bình của tất cả dữ liệu.

- **Bước 2:** Tính ma trận phân tán tích lũy ứng với từng nhóm.

$$S_W = \sum_{j=1}^C \sum_{i=1}^{n_j} (x_{ij} - \mu_j)(x_{ij} - \mu_j)^T \quad (15)$$

- **Bước 3:** Xây dựng hàm tiêu chí tách lớp.

$$W = S_W^{-1} S_B \quad (16)$$

- **Bước 4:** Tính các vector riêng (chọn ra tối đa $C - 1$ vector riêng có giá trị riêng tương ứng lớn nhất) của W . Từ đó hình thành ma trận đổi cơ sở:

$$U = [w_1, w_2, \dots, w_{C-1}] \quad (17)$$

- **Bước 5:** Chuyển các điểm dữ liệu sang không gian mới

$$y = U^T(x - \mu) \quad (18)$$

Ví dụ: Cho tập dữ liệu:

$$X = \begin{pmatrix} 4 & 1 \\ 2 & 4 \\ 2 & 3 \\ 3 & 6 \\ 4 & 4 \\ 9 & 10 \\ 6 & 8 \\ 9 & 5 \\ 8 & 7 \\ 10 & 8 \end{pmatrix} \quad y = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \\ 2 \\ 2 \\ 2 \\ 2 \\ 2 \end{pmatrix}$$

Ta có:

$$\mu_1 = \begin{pmatrix} 3.0 \\ 3.6 \end{pmatrix} \quad \mu_2 = \begin{pmatrix} 8.4 \\ 7.6 \end{pmatrix} \quad \mu = \begin{pmatrix} 5.7 \\ 5.6 \end{pmatrix}$$

- **Bước 1:** Tính S_B

$$S_B = \begin{pmatrix} 29.16 & 21.6 \\ 21.6 & 16.0 \end{pmatrix}$$

- **Bước 2:** Tính S_W

$$S_W = \begin{pmatrix} 2.64 & -0.44 \\ -0.44 & 5.28 \end{pmatrix}$$

- **Bước 3:** Tìm ma trận chuyển không gian, bước này tương tự với các bước từ bước 3 trở về sau của PCA nhưng thay ma trận C bằng ma trận $W = S_W^{-1}S_B$

$$\lambda = 15.65 \implies w = \begin{pmatrix} 0.91 \\ 0.39 \end{pmatrix}$$

- **Bước 4:** Chuyển các điểm dữ liệu về không gian mới ($b = w^T x$)

$$\begin{pmatrix} 4.03 \\ 3.38 \\ 2.99 \\ 5.07 \\ 5.2 \\ 12.09 \\ 8.58 \\ 10.14 \\ 10.01 \\ 12.22 \end{pmatrix}$$

3.2.3 Sự khác biệt giữa PCA và LDA

- PCA giảm chiều dữ liệu không quan tâm đến lớp của dữ liệu đó (Unsupervised Learning). Trong khi LDA lại quan tâm đến lớp của các điểm dữ liệu (Supervised Learning).
- PCA giảm chiều xuống một giá trị K nhỏ hơn số thuộc tính của dữ liệu. Trong khi LDA chỉ có thể giảm số chiều sao cho số chiều giảm xuống phải nhỏ hơn số lớp trong tập dữ liệu.
- LDA sẽ cho kết quả tốt hơn trên tập huấn luyện vì có quan tâm đến nhãn.
- LDA dễ gặp các trường hợp suy biến khi chiều ban đầu của dữ liệu rất lớn như số lượng điểm dữ liệu trong tập lại quá nhỏ. Ví như các dữ liệu ảnh.




Figure 13: So sánh LDA và PCA

3.3 Kiến thức về Support Vector Machines (SVM)

- Chọn hàm *Kernel*.
- Chọn giá trị điều khiển biến cho dữ liệu huấn luyện C .
- Bài toán tối ưu bậc hai để tìm tham số cho vector hỗ trợ.
- Xây dựng hàm tách lớp từ các vector hỗ trợ.

3.3.1 Ví dụ minh họa SVM

- Đối với dữ liệu tuyến tính:




Figure 14: SVM với dữ liệu tuyến tính

- Đối với dữ liệu phi tuyến ta không thể chia trực tiếp bằng các đường thẳng, ta cần phải sử dụng hàm *Kernel* để ánh xạ dữ liệu đó vào không gian nhiều chiều hơn:




Figure 15: SVM với dữ liệu phi tuyến

Ta sử dụng hàm *Kernel* để ánh xạ tập dữ liệu 2 chiều trên thành dữ liệu 3 chiều từ đó dễ dàng tìm ra siêu phẳng để phân lớp hơn.




Figure 16: Tăng chiều dữ liệu bằng các hàm kernel

3.3.2 Một số hàm kernel thông dụng

- Hàm tuyến tính: $K(x_i, x_j) = x_i^T x_j$.
- Hàm đa thức: $K(x_i, x_j) = (1 + x_i^T x_j)^p$
- Gaussian: $K(x_i, x_j) = e^{-\frac{\|x_i - x_j\|^2}{2\sigma^2}}$.
- Sigmoid: $K(x_i, x_j) = \tanh(\beta_0 x_i^T x_j + \beta_1)$

3.3.3 Phân biệt chiến lược one vs all và one vs one

- **One vs One:** Xây dựng rất nhiều bộ binary classifiers cho từng cặp classes. Bộ thứ nhất phân biệt class 1 và class 2, bộ thứ hai phân biệt class 1 và class 3, ... Khi có một dữ liệu mới vào, đưa nó vào toàn bộ các bộ binary classifiers trên. Kết quả cuối cùng có thể được xác định bằng cách xem class nào mà điểm dữ liệu đó được phân vào nhiều

nhất (major voting). Như vậy, nếu có C classes thì tổng số binary classifiers phải dùng là $n(n-1)/2$. Đây là một con số lớn, cách làm này không lợi về tính toán.

- **One vs All:** Nếu có C classes thì ta sẽ xây dựng C classifiers, mỗi classifier tương ứng với một class. Classifier thứ nhất giúp phân biệt class 1 vs not class 1, tức xem một điểm có thuộc class 1 hay không, hoặc xác suất để một điểm rơi vào class 1 là bao nhiêu. Tương tự như thế, classifier thứ hai sẽ phân biệt class 2 vs not class 2, ... Kết quả cuối cùng có thể được xác định bằng cách xác định class mà một điểm rơi vào với xác suất cao nhất.

3.4 Kiến thức về mạng nơron cơ bản (ANN)

3.4.1 Cấu trúc mạng đề nghị

Gồm 3 tầng:

1. tầng nhập ảnh
2. tầng cơ sở gồm 2 bộ phân lớp
 - (a) Bộ phân lớp *nam* hay *nữ*: Bộ phân lớp được huấn luyện với số lượng ảnh *nam* là 5 và số lượng ảnh *nữ* là 8, giúp cho việc huấn luyện bộ phân lớp tốt hơn.
 - (b) Bộ phân lớp *tóc dài* hay *tóc ngắn*: Bộ phân lớp được huấn luyện với số lượng ảnh *tóc dài* là 5 và số lượng ảnh *tóc ngắn* là 8, nhờ vậy cũng giúp cho bộ phân lớp tốt hơn.
3. tầng xuất gồm 4 bộ phân lớp: nhờ các bộ phân lớp ở tầng 2 đã được huấn luyện tốt, các bộ phân lớp ở tầng 3 sẽ chỉ cần ít dữ liệu thậm chí không cần dữ liệu để huấn luyện. Từ đó tránh được các lỗi phân loại sai.
 - (a) Bộ phân lớp có phải *nữ tóc dài*
 - (b) Bộ phân lớp có phải *nam tóc dài*
 - (c) Bộ phân lớp có phải *nữ tóc ngắn*
 - (d) Bộ phân lớp có phải *nam tóc ngắn*

3.4.2 Tính hiệu quả của cấu trúc đề nghị

Nhờ sử dụng thêm một tầng cơ sở chứa 2 bộ phân lớp có phân bố dữ liệu không lệch quá nhiều, nên kết quả của 2 bộ phân lớp trên khá tốt. Nhờ vào đó mà ở tầng 3 chỉ cần tổng hợp kết quả của tầng cơ sở mà không cần huấn luyện. Từ đó giải quyết được vấn đề dữ liệu ở tầng phân lớp ít.

3.5 Kiến thức về mạng nơ-ron sâu (DNN)

3.5.1 mạng nơ-ron sâu thường cho kết quả tốt hơn mạng nơ-ron rộng với cùng số lượng nơ-ron.

Đối với mạng nơ-ron có N nút, mạng học sâu có số tổ hợp các đường đi nhiều hơn rất nhiều so với mạng học rộng chỉ có một lớp. Nhờ đó các giá trị của hàm xấp xỉ sẽ gần đúng với hàm mục tiêu hơn nên cho kết quả tốt hơn. *Ví dụ:* Mạng học rộng ở trên chỉ có 6 đường đi khác nhau từ input đến output. Trong khi đó mạng học sâu bên dưới với 3 lớp ẩn có số đường đi khác nhau từ input đến output là 16.




Figure 17: Lợi ích của mạng học sâu

3.5.2 Hàm kích hoạt (Activation functions)

1. Sigmoid

- Công thức:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

- Ưu điểm: hàm sigmoid có đạo hàm đẹp.
- Nhược điểm:
 - Dễ gây ra các hiện tượng Vanishing / Exploding Gradient khi giá trị đầu vào có trị tuyệt đối quá lớn.
 - Không có zero-centered, gây ảnh hưởng đến tốc độ hội tụ.

2. ReLU

- Công thức:

$$ReLU(x) = \max(0, x)$$

- Ưu điểm:
 - Tính toán nhanh và dễ dàng do không sử dụng hàm tính lũy thừa.
 - Tốc độ hội tụ nhanh.
- Nhược điểm: các nút có giá trị nhỏ hơn 0 qua hàm ReLU sẽ thành 0. Do đó, thông tin từ nút này sẽ không được truyền về cho các nút phía sau.

3. Tanh

- Công thức:

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

- *Ưu điểm*: giống với hàm sigmoid. Hàm tanh có đạo hàm đẹp. Ngoài ra, khác với sigmoid thì hàm tanh có trung tâm là 0 (zero - centered) nhờ đó mà hội tụ tốt hơn sigmoid.
- *Nhược điểm*: Hàm tanh có 2 đầu bão hòa giống với sigmoid. Điều này dẫn đến gradient biến mất hoặc bùng nổ.

3.5.3 Bộ tối ưu (Optimizer)

1. Gradient Descent (GD):

- Tính hàm độ lỗi của toàn bộ dữ liệu huấn luyện. Sau đó tính đạo hàm và tối ưu các tham số tham chiều ngược với đạo hàm.

- Công thức:

$$x_{t+1} = x_t + \eta f'(x_t) \text{ , trong đó } \eta \text{ là Learning Rate}$$

- *Ưu điểm*: thuật toán dễ hiểu. Tối ưu được các tham số của mô hình sau các vòng lặp.
- *Nhược điểm*: nghiệm tìm được phụ thuộc rất nhiều vào nghiệm khởi tạo ban đầu và learning rate. Các nghiệm khởi tạo khác nhau có thể bị rơi vào các cực trị cục bộ khác nhau và có thể không phải là nghiệm toàn cục. Learning rate quá lớn hoặc quá nhỏ sẽ làm cho quá trình hội tụ diễn ra rất lâu hoặc thậm chí không thể hội tụ.

2. Stochastic Gradient Descent (SGD)

- Sử dụng công thức giống với Gradient Descent. Nhưng ở mỗi epoch, ta cần tính hàm độ lỗi cho một số điểm dữ liệu và cập nhật trọng số.
- *Ưu điểm*: đối với tập dữ liệu lớn, GD không thể tính các giá trị như hàm độ lỗi và đạo hàm một cách nhanh chóng. Tuy nhiên đối với SGD thì việc này trở nên dễ dàng.
- *Nhược điểm*: giống với GD, SGD chưa giải quyết được vấn đề phụ thuộc và điểm trọng số khởi tạo và learning rate.

3. Momentum

- Momentum khắc phục nhược điểm của GD và SGD bằng cách thêm một lượng quán tính vào công thức tối ưu tham số. Do đó, dù có đạt đến cực tiểu, các tham số sẽ trượt lên một đoạn để có thể thoát ra khỏi cực trị địa phương hoặc là lặn ngược xuống về điểm cực trị ban đầu.
- Công thức:

$$v_t = \gamma v_{t-1} + \eta f'(x) \tag{19}$$

$$\phi = \phi - v_t \tag{20}$$

- *Ưu điểm*: thuật toán dễ hiểu. Tối ưu được các tham số của mô hình sau các vòng lặp.

- *Nhược điểm*: nghiệm tìm được phụ thuộc rất nhiều vào nghiệm khởi tạo ban đầu và learning rate. Các nghiệm khởi tạo khác nhau có thể bị rơi vào các cực trị cục bộ khác nhau và có thể không phải là nghiệm toàn cục. learning rate quá lượng hoặc quá nhỏ sẽ làm cho quá trình hội tụ diễn ra rất lâu hoặc thậm chí không thể hội tụ.

3.5.4 Drop-out

Định nghĩa: Drop-out là kĩ thuật giúp giảm tỉ lệ overfitting của mạng nơron nhân tạo. Trong khi phương pháp Regularization trước đó đánh phạt cho trọng lượng của các tham số. Drop-out bỏ qua ngẫu nhiên một số nút trong quá trình huấn luyện theo một tỉ lệ $1-p$ (p được gọi là *Keeping prob*). Nhờ vậy mà một nút mạng không thể phụ thuộc nhiều vào một nút mạng nào đó được (Vì không biết khi nào nút sẽ bị drop-out), từ đó mà độ phụ thuộc (trọng lượng) của các nút liên kết tới sẽ được trải đều, giúp tăng sức mạnh cho các nút mạng trong mạng.

Hệ số p nên ở khoảng $[0.2, 0.5]$. Nếu p quá nhỏ thì không có tác dụng chống overfitting, tuy nhiên nếu p quá lớn thì gần như loại bỏ layer đấy và có thể dẫn đến underfitting.

Drop-out được thực hiện trên tập validation và chia làm 2 giai đoạn:

- **Training**: Với mỗi epoch, với mỗi mini-batch, ta thực hiện drop-out với tỉ lệ drop là $(1-p)$ trên mỗi lớp ẩn.
- **Testing**: Ở giai đoạn testing, ta không thực hiện drop-out trên mạng. Và phải nhân một lượng p vào mỗi tham số để tránh output bị nhân lên gấp đôi.




Figure 18: Minh họa Drop-out

4 Bài tập

4.1 Locally Linear Embedding (LLE)

4.1.1 Tổng quan

Locally Linear Embedding (LLE) là một thuật toán học không giám sát (Unsupervised Learning) dùng để giảm chiều dữ liệu phi tuyến thuộc nhóm *Manifold*.




Figure 19: Manifold

Giải thuật LLE được nhóm tác giả *Sam T. Roweis* và *Lawrence K. Saul* trình bày trong bài báo "Nonlinear Dimensionality Reduction by Locally Linear Embedding" vào năm 2000.

4.1.2 Các bài toán liên quan

1. Face Recognition with Weighted Locally Linear Embedding.

Bài toán nhận dạng khuôn mặt kết hợp với giảm chiều dữ liệu bằng thuật LLE. Qua các thực nghiệm, người ta có thể thấy rằng không gian các ảnh khuôn mặt là không gian phi tuyến có dạng đa tạp. Do đó, thuật toán LLE với khả năng giảm chiều dữ liệu phi tuyến của mình, có thể cho ra kết quả phân lớp tốt hơn so với sử dụng các giải thuật giảm chiều kinh điển như PCA.

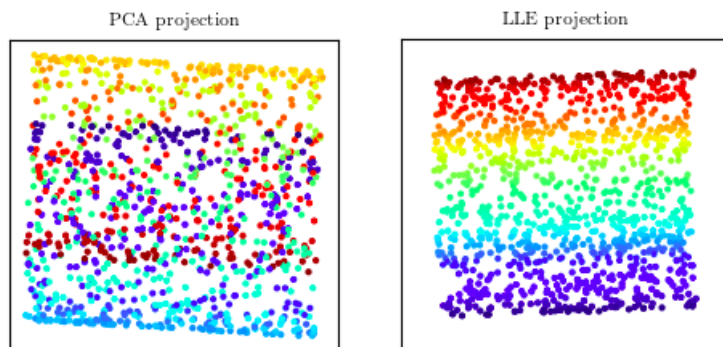


Figure 20: So sánh giảm chiều sử dụng PCA và LLE trên manifold

2. Audio Fingerprint Extraction Based on Locally Linear Embedding for Audio Retrieval System.

Bài toán so sánh giọng nói của một người với dữ liệu giọng nói trong database. Vấn đề của bài toán là dữ liệu âm thanh cần lưu trữ quá lớn và ảnh hưởng đến tốc độ chạy của hệ thống. Do đó, cần phải sử dụng thuật giảm chiều LLE để có thể biểu diễn âm thanh nhận dạng tốt hơn trong tập dữ liệu, giúp giảm bớt không gian lưu trữ và thời gian chạy được cải thiện.

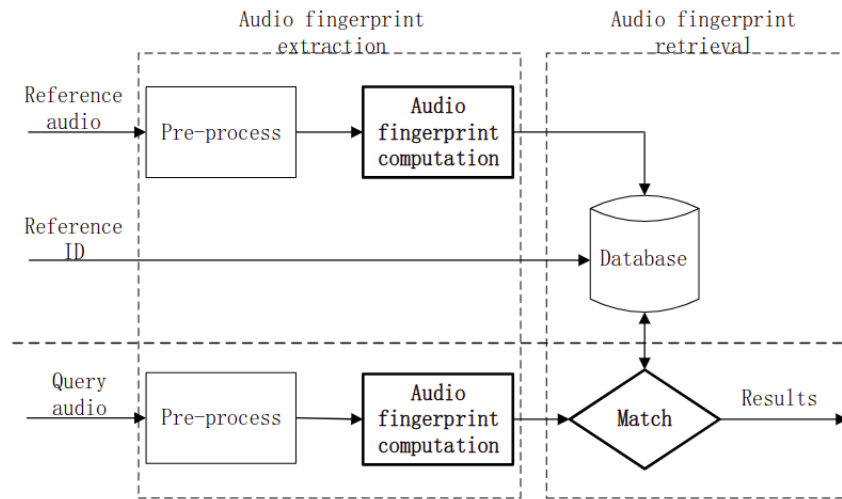


Figure 21: Hệ thống nhận dạng giọng nói

3. Supervised Locally Linear Embedding Algorithm for Hand Writing Recognition.

Bài toán nhận dạng chữ viết tay nói riêng và các bài toán nhận dạng mẫu nói chung thường gặp khó khăn khi chiều của dữ liệu tăng lên. Nhất là khi lượng dữ liệu trong tập không nhiều trong bài toán nhận dạng chữ viết tay. Chiều dữ liệu lớn làm cho việc nhận dạng trở nên khó khăn và tốn nhiều thời gian. Vì lý do đó, ta có thể sử dụng các thuật toán giảm chiều.

Bài toán sử dụng một biến thể của LLE là *Supervised LLE* (SLLE) để có thể áp dụng trên bài toán học có giám sát. Nhờ vào giảm chiều, sẽ tránh được các vấn đề về thiếu dữ liệu và chiều không gian lớn gây ảnh hưởng đến tính hiệu quả của giải thuật.

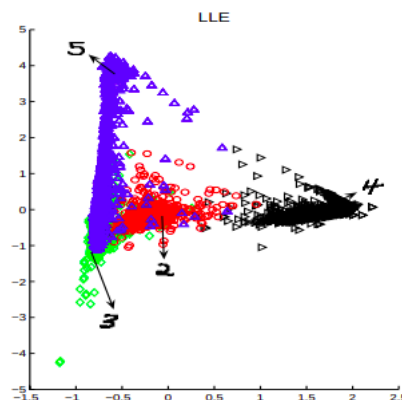


Figure 22: Hand writing Manifold

4.1.3 Mô tả thuật toán LLE

1. Với mỗi điểm dữ liệu p chiều, ta tìm k láng giềng gần nhất của nó.
2. Tìm ma trận W sao cho tổng bình phương lỗi khi tái cấu trúc tuyến tính mỗi x_i đạt giá trị nhỏ nhất:

$$\varepsilon(W) = \sum_{i=1}^m \epsilon_i = \sum_{i=1}^m \left\| x_i - \sum_{j=1}^n w_{ij} x_j \right\|^2 \quad (21)$$

3. Tìm Y sao cho tổng bình phương độ lỗi của quá trình tái cấu trúc đạt giá trị nhỏ nhất:

$$\Theta(Y) = \sum_{i=1}^n \left\| y_i - \sum_{j=1}^n w_{ij} y_j \right\|^2 \quad (22)$$

4.1.4 Đánh giá giải thuật

• Ưu điểm

- *Siêu tham số*: Chỉ cần gán trước 2 siêu tham số.
- *Tối ưu*: không liên quan đến cực tiểu cục bộ.
- *Bảo toàn thông tin*: Thông tin không gian cục bộ trong không gian nhiều chiều được bảo toàn trong không gian con.
- *Độ phức tạp*: LLE được cài đặt trong bộ thư viện scikit-learn là:

$$\mathcal{O}[D \log(k) m \log(m)] + \mathcal{O}[D m k^3] + \mathcal{O}[d m^2]$$

Có thể thấy thuật toán chạy trong thời gian đa thức và phụ thuộc mạnh mẽ vào số lượng láng giềng k .

- *Thư viện hỗ trợ*: Trong python, Locally Linear Embedding được cài đặt trong thư viện scikit-learn (`sklearn.manifold.LocallyLinearEmbedding`).

• Nhược điểm

- Nếu mật độ các mẫu không dày, hoặc việc lấy mẫu không đều, có thể tạo ra các manifold không đồng nhất, hay nói cách khác có nhiều manifold hình thành nên bộ dữ liệu, từ đó gây ra hiểu nhầm trong lúc chạy thuật.
- LLE rất nhạy cảm với nhiễu, với một lượng nhiễu nhỏ cũng có thể dẫn đến lỗi khi tạo embedding.
- Không đảm bảo 2 điểm khác nhau trong không gian nhiều chiều sẽ khác nhau trong không gian giảm chiều.
- Phụ thuộc nhiều vào 2 siêu tham số k và d . Việc chọn 2 siêu tham số không tốt có thể dẫn đến thuật toán không cho kết quả tốt.
- Chỉ dùng cho các bài toán học không giám sát. (Sau đó đã có các biến thể SLLE để giải quyết các bài toán học có giám sát).

4.2 ArcFace

4.2.1 Bài toán

Các mạng học sâu giải quyết các bài toán phân lớp gương mặt thường sử dụng hàm lỗi softmax để tính xác suất của một ảnh gương mặt thuộc về đối tượng nào. Nhưng khi số lượng ảnh trong cơ sở dữ liệu tăng đáng kể ngày nay, hàm softmax khó có thể phân biệt các điểm dữ liệu ở gần biên của 2 đối tượng khác nhau.

ArcFace sử dụng hàm lỗi Additive Angular Margin với mục tiêu gom các ảnh cùng một đối tượng lại gần nhau và các cụm đối tượng khác nhau sẽ xa nhau trong không gian latent space. Từ đó, tăng được độ hiệu quả trong các bài toán nhận dạng mặt người.

ArcFace là một giải pháp được phát triển bởi InsightFace - một dự án open source cung cấp thư viện các thuật toán nhận dạng gương mặt 2D và 3D. Được trình bày trong bài báo "Additive Angular Margin Loss for Deep Face Recognition" được đăng tải trên *arxiv.org* vào 23/01/2018.

Đối tượng tiềm năng cho giải pháp này là các hệ thống an ninh của chính phủ, khi cần quản lý rất nhiều các đối tượng khác nhau. Hơn thế, đôi khi có các đối tượng có gương mặt khá giống nhau khiến cho khoảng cách giữa chúng trong latent space khá gần nhau dẫn đến khó nhận dạng.

Ta có thể tìm thấy các thông tin về ArcFace như demo minh họa, bài báo khoa học, mã nguồn tại trang <https://insightface.ai/arcface>

4.2.2 Tính năng chủ đạo

Tính năng chủ đạo của giải pháp là gom các embedding của cùng một đối tượng lại gần nhau và tách rời các cụm đối tượng ra xa nhau. Cụ thể thuật toán hoạt động như sau:

ArcFace đã đưa ra ý tưởng sử dụng các vector tham số làm tâm của các lớp và từ đó tối ưu "khoảng cách" giữa các điểm dữ liệu đến tâm của nó. Ta có thể hình dung được rõ hơn qua công thức sau đây:

$$W_j^T x_i = \|W_j\| \cdot \|x_i\| \cos \theta_j \quad (23)$$

Với W_j là vector tham số tương ứng với lớp thứ j , x_i là điểm dữ liệu và θ_j là góc giữa W_j và x_i .

Ta thực hiện chuẩn hóa (L_2 normalisation) lên các vector W_j và x_i . Và nhân các x_i với 1 lượng s . Bằng cách chuẩn hoá như trên, ta sẽ có $\|W_j\| = 1$ và $\|x_i\| = s$, nhờ đó mà dự đoán khi phân lớp chỉ phụ thuộc vào θ_j . Công thức (7) được đổi thành:

$$L_2 = -\frac{1}{N} \sum_{i=1}^N \log \frac{e^{s \cos \theta_{y_i}}}{e^{s \cos \theta_{y_i}} + \sum_{j=1, j \neq y_i}^N e^{s \cos \theta_j}} \quad (24)$$

Từ (10), ta có thể hình dung ra các embedding sẽ tập trung xung quanh các tâm của lớp và phân bố trên 1 mặt siêu cầu (*hypersphere*). Sau đó, ta cộng một siêu tham số m (*Additive Angular Margin*) vào góc giữa x_i và W_j để có thể tối ưu tốt hơn các khoảng cách giữa các

embedding. Minh hoạ bằng hình bên dưới, ta thấy khi sử dụng hàm *Softmax loss* để phân lớp, đường ranh giới giữa các lớp rất mờ, khiến cho việc phân lớp cho các điểm gần ranh giới này dễ xảy ra sai sót. Còn đối với *Additive angular margin loss* bằng các sử dụng margin để ngăn cách giữa các lớp, Các điểm dữ liệu co cụm lại gần tâm của nó để lại một khoảng cách xa giữa các lớp từ đó giúp quá trình phân lớp ít lỗi hơn.

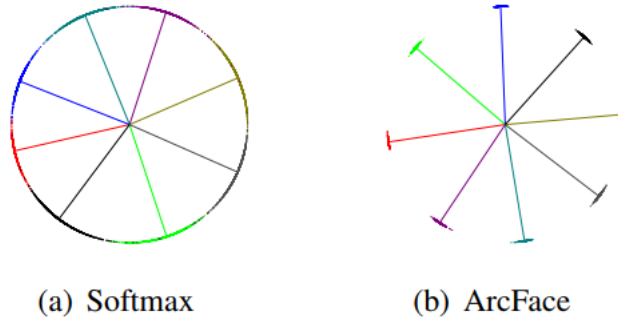


Figure 23: So sánh giữa softmax và arcface

Ưu điểm

- Độ phức tạp thấp, hiệu suất cao, lập trình dễ dàng.
- Có độ hội tụ tốt trên các tập dữ liệu khác nhau mà không cần kết hợp thêm hàm độ lỗi nào khác.

Nhược điểm

- Khi số lượng các lớp tăng lên thì ma trận W cũng sẽ tăng lên đáng kể.
- Sử dụng hàm arccos khi chi phí tính toán chưa tối ưu.

Tiềm năng phát triển: *ArcFace* đang mở ra các hướng đi mới trong việc giải quyết các bài toán nhận dạng khuôn mặt với số đối tượng cần nhận dạng quá nhiều. Có thể thấy sự phát triển của giải pháp này trong quá khứ từ *SphereFace* đến *CosFace* và giờ là *ArcFace* đang là state-of-the-art trong các bài toán nhận dạng khuôn mặt. Và trong tương lai, hướng giải quyết này sẽ còn có khả năng phát triển để có thể giúp các tổ chức chính phủ quản lý người dân, thắt chặt an ninh và truy vết, bắt giữ các phần tử nguy hiểm trong xã hội nhanh chóng.

Có thể có cái nhìn tổng quát hơn về khác biệt của các độ lỗi bằng hình bên dưới, có thể thấy các phương pháp *SphereFace* và *CosFace* có các đường biên quyết định (*decision boundary*) có dạng phi tuyến, trong khi *ArcFace* lại cho kết quả tuyến tính giúp phân lớp dễ dàng hơn.




Figure 24: So sánh giữa các độ lỗi

4.3 Đa dạng trong giải thuật học máy

4.3.1 Bài toán

Bài toán *Speech Recognition* với đầu vào là một đoạn audio được thu âm và đầu ra là đoạn văn bản chính xác câu của người nói.

4.3.2 Giải pháp sử dụng CNN

- Giải pháp sử dụng mạng CNN kết hợp với HMM.
- **Tư tưởng chủ đạo:** Sử dụng mạng CNN để học xác suất hậu nghiệm của đoạn âm thanh, từ đó HMM sử dụng output của CNN để dự đoán các likelihood của từng frame âm thanh. Các likelihood này sẽ được Viterbi decoder tạo ra đoạn văn bản hoàn chỉnh.
- **Các bước chính:**
 - **Bước 1:** Đoạn âm thanh ở miền thời gian được chuyển thành melspectrogram.
 - **Bước 2:** Melspectrogram sau đó được đưa vào mạng CNN và qua một lớp softmax để output được xác suất hậu nghiệm.
 - **Bước 3:** Xác suất hậu nghiệm này sẽ được sử dụng để dự đoán các likelihood của từng frame.
 - **Bước 4:** Các likelihood sẽ được bộ giải mã Viterbi chuyển thành đoạn văn bản hoàn chỉnh.
 - **Bước 5:** So sánh đoạn văn bản dự đoán và đoạn văn bản đúng để học các tham số trong mô hình.
- **Bài báo khoa học:** Tại đây.
- **Ưu điểm:**
 - Số ượng tham số ít hơn so với sử dụng DNN. Nhờ sử dụng weight sharing.
 - Có thể học được các đặc trưng phân cấp của đoạn âm thanh.
- **Nhược điểm:**
 - Cần sử dụng nhiều dữ liệu, trong khi để thu thập được một lượng lớn âm thanh và transcript cho từng đoạn âm thanh đôi khi gặp nhiều khó khăn.

- Do sử dụng nhiều dữ liệu, nên tài nguyên tính toán cũng tăng theo đáng kể dẫn đến cần các tài nguyên phân cứng mạnh để có thể chạy các mô hình CNN.

4.3.3 Giải pháp sử dụng RNN

- Giải pháp sử dụng mạng Bidirectional LSTM kết hợp với CTC loss.
- **Tư tưởng chủ đạo:** Với mỗi timestep sẽ dự đoán xem frame tiếp theo sẽ là ký tự nào (các khả năng sẽ gồm tất cả các ký tự và một ký tự rỗng). Từ đoạn văn bản thô đầu, ta hình thành đoạn văn bản kết quả theo quy tắc: các ký tự (Không bao gồm ký tự rỗng) giống nhau liên tiếp sẽ gom lại thành một ký tự.

Ví dụ: ký tự rỗng được biểu diễn bằng "-"

- "hhh—e—ll—lll—oo— —www—oooo—r—ll—dd" → "hello world"
- "SS—ooo—n— —dd—e—pppp— —t—rr—aaa—iiiiiiiiiii" → "Son dep trai"

- **Các bước chính:**
 - **Bước 1:** Đoạn âm thanh ở miền thời gian được chuyển thành melspectrogram.
 - **Bước 2:** Từng frame x_t của melspectrogram sẽ được input vào BLSTM và output ra vector y_t với ý nghĩa là độ thuộc của x_t với các ký tự trong tập dự đoán. y_t sẽ được đưa vào một lớp softmax để thu được phân bố xác suất của ký tự thứ k tại frame thứ t ($Pr(k|t)$)
 - **Bước 3:** Sử dụng Gradient Descent để học các tham số của CTC và BLSTM.
- **Bài báo khoa học:** Tại đây
- **Ưu điểm:** do là mô hình theo kiến trúc end-to-end nên sẽ không cần quan tâm đến các giai đoạn như tiền xử lý hay rút trích đặc trưng của dữ liệu đầu vào. Đoạn âm thanh sẽ được chuyển trực tiếp thành văn bản thông qua mô hình.
- **Nhược điểm:** Mô hình sử dụng chiến thuật tham lam khi phân bố xác suất ở mỗi timestep chỉ phụ thuộc vào ký tự trước đó. Để giải quyết vấn đề này. Trong bài báo trên, nhóm tác giả có đề xuất sử dụng RNN Transducer để có độ phân bố của ký tự dự đoán so với tất cả các ký tự trước đó đã được dự đoán. Sau đó sử dụng Beam Search để decode ra ký tự dự đoán.

5 Tài liệu tham khảo

- Slide bài giảng trên trang môn học.
- Adjacent Evaluation LPB
- Bài 27: Principal Component Analysis (machinelearningcoban)
- Bài 29: Linear Discriminant Analysis(machinelearningcoban)
- Bài 19: Support Vector Machine (machinelearningcoban)
- Bài 21: Kernel Support Vector Machine (machinelearningcoban)
- Bài 12: Binary Classifiers cho các bài toán Classification (machinelearningcoban)
- Hàm kích hoạt (activate function)
- Tối ưu (Optimizer)
- Kỹ thuật Drop-out
- Thuật toán LLE
- Comparison of PCA and Manifold Learning
- Face recognition with weighted locally linear embedding
- Audio Fingerprint Extraction Based on Locally Linear Embedding for Audio Retrieval System
- Supervised Locally Linear Embedding Algorithm for Pattern Recognition
- ArcFace: Additive Angular Margin Loss for Deep Face Recognition
- ArcFace explained video
- ArcFace for face verification